

**Nombre y Apellidos: Susana Fraga Ortiz**

**Github con notebook:**

*Nota: Por favor, seguir esta estructura para el documento*


## 1. Resumen Ejecutivo

*Máximo 2 páginas*

El análisis realizado tiene como objetivo identificar los factores que explican el riesgo clínico de los asegurados y construir un modelo predictivo capaz de clasificar a los pacientes entre alto y bajo riesgo.

Para ello, se llevó a cabo un análisis exploratorio de los datos (más centrado en el coste que en el riesgo), un estudio de correlaciones para eliminar variables redundantes y un modelo final basado en **regresión logística**, seleccionando únicamente variables no colineales y relevantes desde el punto de vista clínico, demográfico y de utilización sanitaria.

El dashboard elaborado resume visualmente los hallazgos más importantes del análisis.



En primer lugar, la distribución del riesgo muestra que existe un grupo significativo de pacientes clasificados como alto riesgo, lo que justifica la necesidad de un modelo capaz de anticipar estos casos.

El boxplot de visitas médicas revela que los pacientes de alto riesgo presentan un número mayor de visitas al sistema sanitario, reforzando la idea de que la utilización del sistema es un indicador relevante del riesgo clínico.

La curva ROC del modelo confirma su excelente rendimiento, con un AUC cercano a 0.998, lo que implica que el modelo distingue casi perfectamente entre pacientes de alto y bajo riesgo.

Además, el gráfico de coeficientes permite identificar cuáles son las variables más influyentes: predominan las condiciones clínicas como hipertensión, diabetes, enfermedades pulmonares o renales, junto con factores de utilización como hospitalizaciones y visitas médicas. Hábitos de vida como el IMC elevado y el tabaquismo también incrementan la probabilidad de riesgo, mientras que algunas características de la póliza tienen una influencia más moderada.

A partir de estos resultados, se pueden extraer varias recomendaciones accionables para la aseguradora.

- En primer lugar, conviene priorizar programas de seguimiento para pacientes con enfermedades crónicas y patologías de alto impacto, ya que concentran gran parte del riesgo.
- Realizar intervenciones tempranas en pacientes con alta utilización del sistema sanitario para prevenir complicaciones y reducir costes futuros.
- La promoción de hábitos saludables, especialmente en relación con el peso y el consumo de tabaco, puede ayudar a disminuir la aparición de factores de riesgo.
- Por último, optimizar los planes de salud y ajustar coberturas en función del perfil de riesgo.


Además del modelo predictivo orientado a identificar pacientes de alto riesgo, se realizó un análisis exploratorio del coste médico anual para entender mejor los factores que impulsan el gasto sanitario.

- Las visualizaciones mostraron que el coste presenta una distribución muy concentrada en valores bajos, mientras que un pequeño grupo de pacientes concentra gastos extremadamente altos.
- También se observó que el coste aumenta de forma clara con el número de enfermedades crónicas, y que los pacientes con mayor utilización del sistema tienden a generar un gasto significativamente mayor.
- El análisis del BMI junto al tabaquismo indicó que los fumadores concentran los costes más elevados
- Finalmente, al comparar el coste entre grupos de riesgo, los pacientes clasificados como alto riesgo presentan una mediana más alta y una mayor dispersión

En conjunto, el modelo desarrollado, los hallazgos descriptivos y el dashboard proporcionan una visión clara y accionable del riesgo clínico de los asegurados, ofreciendo una herramienta útil para la planificación, prevención y toma de decisiones en la gestión sanitaria.


## 2. Gráficas del análisis exploratorio y breve explicación de cada una

### 1. Distribución del coste medio anual



La gráfica muestra la distribución del coste médico anual de los asegurados y revela una **asimetría muy marcada hacia la derecha**, donde la mayoría de los individuos presenta gastos bajos o moderados (principalmente por debajo de 10.000), mientras que una minoría concentra costes extremadamente altos que pueden superar los 60.000. Esto sugiere que un pequeño grupo de asegurados, probablemente con enfermedades crónicas, hábitos de vida poco saludables o uso intensivo de servicios médicos, genera la mayor parte del gasto total.


### 2. Relación de la edad con el coste médico anual



En este caso observamos como la concentración del coste anual está entre las personas con edades entre los 30 y 70 años de edad, pero sin mucha diferencia entre todos ya que los costes aparecen muy dispersos a lo largo de todas las edades. Sin embargo, se observa una tendencia leve a mayores costes en edades más avanzadas, especialmente a partir de los 50-60 años, donde empiezan a aparecer casos de gasto elevado que no se ven en edades tempranas.

En conjunto, la dispersión sugiere que la edad por sí sola no explica completamente el nivel de coste, por lo que otros factores, como enfermedades crónicas, hábitos de vida o características del plan de seguro, probablemente desempeñan un papel más determinante en el gasto sanitario.

### 3. Correlaciones de las variables numéricas entre sí




La matriz de correlación muestra que la mayoría de las variables numéricas presentan correlaciones bajas entre sí, lo que indica que el dataset es relativamente heterogéneo.

Se observan bloques de correlación moderada en variables relacionadas con el uso de servicios médicos (visitas, hospitalizaciones, días hospitalizado), con enfermedades crónicas (diabetes, hipertensión, cardiopatías y otras) y con variables económicas del seguro (prima anual, prima mensual y monto de reclamaciones).

Además, el coste médico anual y el total de reclamaciones pagadas muestran correlaciones positivas claras con el número de condiciones crónicas y el riesgo clínico, reforzando la idea de que la carga de enfermedad y el uso intensivo de recursos sanitarios son los principales impulsores del gasto.


#### 4. Coste medio anual según el número de enfermedades crónicas



La gráfica muestra cómo el coste médico anual aumenta de forma clara y progresiva a medida que un asegurado acumula más enfermedades crónicas: quienes no presentan ninguna condición tienen un coste medio reducido, pero el gasto crece de manera sostenida para 1, 2, 3 y 4 enfermedades, hasta dispararse en los casos con 6 condiciones crónicas, donde el coste medio es muy superior al del resto.


Esta relación refuerza la idea de que la carga de enfermedad es uno de los principales determinantes del gasto sanitario, y justifica que los pacientes con muchas patologías sean considerados de alto riesgo por su impacto económico y clínico.

## 5. Coste anual según BMI



La gráfica muestra la relación entre el BMI y el coste médico anual diferenciando por un el hábito de fumador, y se observa que, aunque no existe una correlación lineal fuerte con el BMI, los fumadores actuales (“Current”) tienden a concentrar los costes más altos, especialmente en los valores extremos de gasto, mientras que los no fumadores presentan una dispersión más moderada. Esto sugiere que el tabaquismo está asociado con un mayor coste sanitario, reforzando la relevancia de los hábitos de vida como factor de riesgo clave para la aseguradora.

## 6. Coste médico anual según el nivel de riesgo



La gráfica compara el coste médico anual entre asegurados clasificados como de alto riesgo frente a los de bajo riesgo, mostrando que el grupo de alto riesgo presenta una mediana más elevada y una mayor concentración de costes altos, junto con una mayor presencia de outliers extremos.

Aunque ambos grupos contienen casos con gastos muy elevados, la distribución del grupo de riesgo 1 es claramente más alta y más dispersa.

## 3. Modelo predictivo explicado y con tablas

He realizado un modelo de **Regresión Logística** (clasificación) para la variable ***is\_high\_risk*** (*variable binaria*). El objetivo por lo tanto es predecir si un paciente pertenece o no a la categoría de alto riesgo clínico. La variable objetivo indica si el paciente presenta un perfil clínico de alto riesgo (1) o no (0).

Este tipo de predicción resulta especialmente relevante para una aseguradora, ya que permite identificar a los pacientes que probablemente generen mayores costes sanitarios o que requieran un seguimiento clínico más estrecho.

Para la selección de variables del modelo, he realizado previamente un análisis de las variables numéricas que tuviesen un alto grado de correlación para saber cuáles utilizar en esta clasificación (gráfica 3 del apartado anterior). También se ha eliminado la variable `risk_score` por ser muy parecida a la propia variable que se ha decidido predecir. Finalmente, se seleccionaron **27 variables** de distintas categorías:

#### **Demográficas**

- Edad (`age`)
- Sexo (`sex`)
- Región (`region`)
- Tipo de zona (`urban_rural`)
- Nivel de ingresos (`income`)

#### **Hábitos de vida**

- Índice de masa corporal (`bmi`)
- Tabaquismo (`smoker`)
- Consumo de alcohol (`alcohol_freq`)

#### **Condiciones clínicas**

- Número de enfermedades crónicas (`chronic_count`)
- Hipertensión (`hypertension`)
- Diabetes (`diabetes`)
- Enfermedad pulmonar obstructiva crónica (`copd`)
- Enfermedad renal (`kidney_disease`)
- Enfermedad hepática (`liver_disease`)
- Artritis (`arthritis`)
- Salud mental (`mental_health`)
- Historial de cáncer (`cancer_history`)

#### **Utilización del sistema sanitario**

- Visitas médicas anuales (`visits_last_year`)
- Hospitalizaciones en los últimos 3 años (`hospitalizations_last_3yrs`)
- Número de medicamentos activos (`medication_count`)
- Consultas/procesos médicos (`proc_consult_count`)

#### **Características de la póliza**

- Deducible (`deductible`)
- Copago (`copay`)
- Tipo de plan médico (`plan_type`)
- Nivel de red (`network_tier`)
- Calidad del proveedor (`provider_quality`)
- Duración de la póliza (`policy_term_years`)
- Cambios de póliza en los últimos 2 años (`policy_changes_last_2yrs`)

Para las variables categóricas, se hizo uso de OneHotEncoder para que pasasen a ser numéricas (0,1,2, etc) y que las supiese interpretar el modelo.



El modelo se entrenó con un conjunto de entrenamiento del 80% y se evaluó con un 20% restante de test.

Para medir su rendimiento se utilizaron las métricas habituales en clasificación:

### **AUC (Area Under the ROC Curve)**

El AUC mide la capacidad del modelo para distinguir entre pacientes de alto y bajo riesgo.


Un AUC elevado indica un buen desempeño en la clasificación. Y en este caso, se ha obtenido un AUC muy elevado de 0,998. Quizás esto me lleva a pensar que hay algo mal en el modelo, pero es lo que me ha salido.

|                         |           |        |          |         |  |
|-------------------------|-----------|--------|----------|---------|--|
| AUC: 0.9976612867294594 |           |        |          |         |  |
|                         | precision | recall | f1-score | support |  |
| 0                       | 0.98      | 0.98   | 0.98     | 12644   |  |
| 1                       | 0.96      | 0.96   | 0.96     | 7356    |  |
| accuracy                |           |        | 0.97     | 20000   |  |
| macro avg               | 0.97      | 0.97   | 0.97     | 20000   |  |
| weighted avg            | 0.97      | 0.97   | 0.97     | 20000   |  |

### **ROC**

La curva ROC muestra cómo de bien el modelo distingue entre pacientes de alto y bajo riesgo. Cuanto más se acerca la curva a la esquina superior izquierda, mejor es el rendimiento del modelo.

En este caso, la curva se encuentra prácticamente pegada al borde superior, lo que indica una capacidad de discriminación excelente.



### Interpretación del modelo: Coeficientes

A continuación, se evaluó la importancia de las variables del modelo obteniendo los siguientes valores:

|    | feature                    | coef      | abs_coef  |
|----|----------------------------|-----------|-----------|
| 32 | smoker_Current             | 11.380607 | 11.380607 |
| 0  | age                        | 10.838437 | 10.838437 |
| 3  | chronic_count              | 9.863078  | 9.863078  |
| 34 | smoker_Never               | -5.694770 | 5.694770  |
| 33 | smoker_Former              | -5.690511 | 5.690511  |
| 2  | bmi                        | 1.915799  | 1.915799  |
| 24 | region_Central             | 0.098322  | 0.098322  |
| 39 | plan_type_EPO              | 0.091350  | 0.091350  |
| 30 | urban_rural_Suburban       | -0.090395 | 0.090395  |
| 41 | plan_type_POS              | -0.089834 | 0.089834  |
| 21 | sex_Female                 | -0.089041 | 0.089041  |
| 29 | urban_rural_Rural          | 0.079341  | 0.079341  |
| 23 | sex_Other                  | 0.060902  | 0.060902  |
| 13 | hospitalizations_last_3yrs | -0.047610 | 0.047610  |
| 28 | region_West                | -0.045329 | 0.045329  |
| 26 | region_North               | -0.044960 | 0.044960  |
| 42 | plan_type_PPO              | -0.042487 | 0.042487  |
| 12 | visits_last_year           | 0.040433  | 0.040433  |
| 38 | alcohol_freq_Weekly        | -0.040405 | 0.040405  |
| 11 | cancer_history             | -0.039809 | 0.039809  |

### Gráfico de coeficientes

Además de la tabla, se generó un gráfico de barras con las 15 variables más influyentes del modelo, lo que facilita la interpretación visual y la explicación de los factores que más contribuyen al riesgo clínico.

El gráfico muestra las variables con mayor influencia en la predicción del riesgo clínico:

- Las barras **hacia la derecha** indican variables que **aumentan** la probabilidad de que un paciente sea de alto riesgo.
- Las barras **hacia la izquierda** indican variables que **reducen** dicha probabilidad.
- La longitud de cada barra representa la **importancia** de cada variable en el modelo.

En este caso, las variables con mayor impacto en el riesgo son principalmente factores clínicos y de utilización médica, como el **número de enfermedades crónicas**, la **presencia de patologías** relevantes o la **frecuencia de hospitalizaciones y visitas médicas**.

Estas variables permiten identificar qué perfiles de pacientes concentran mayor riesgo.

